

真实数据分析实验结果与解释

本文档说明 `GBM_methylation.py` 对 LGG 与 GBM DNA 甲基化数据进行真实数据分析后得到的最终结果，并解释 `GBM_plot/plot_fig2_qq.py` 生成的 Fig. 2 风格 QQ 图。

1. 数据与实验目标

真实数据来自 `GBM/` 文件夹：

- `GBM_prognostic_low.txt`：LGG 组甲基化数据，样本量 `n1 = 511`。
- `GBM_prognostic_high.txt`：GBM 组甲基化数据，样本量 `n2 = 150`。
- 每个样本包含 `p = 207` 个与 glioma prognosis 相关的基因。

实验目标是检验 LGG 与 GBM 两组样本的 DNA 甲基化分布是否相同。使用的方法是论文提出的稀疏 max-sliced Wasserstein distance 与 bootstrap 两样本检验。

原假设与备择假设为：

- `H0`：LGG 与 GBM 的甲基化分布相同
- `H1`：LGG 与 GBM 的甲基化分布不同

2. 全局两样本检验结果

全局检验结果保存在：

- `GBM/GBM_global_test_summary.txt`

本次运行得到的关键数值如下：

指标	数值
LGG 样本量 <code>n1</code>	511
GBM 样本量 <code>n2</code>	150
基因维度 <code>p</code>	207
显著性水平 <code>alpha</code>	0.05
bootstrap 次数 <code>B</code>	500
选择的稀疏参数 <code>lam_10</code>	50.000003814697266
max-sliced Wasserstein 距离 <code>mswd_10</code>	3.986034870147705
检验统计量	42.92362976074219
bootstrap 临界值	1.8478721380233765
empirical p-value	0.0
是否拒绝原假设	是

由于检验统计量 42.9236 远大于 bootstrap 临界值 1.8479，因此在 $\alpha = 0.05$ 水平下拒绝原假设。也就是说，LGG 与 GBM 两组样本的 DNA 甲基化分布存在显著差异。

这里的 $p_value = 0.0$ 是基于 500 次 bootstrap 的经验 p 值，表示 500 个 bootstrap 统计量中没有一个超过观测统计量。因此更稳妥的表述是：

```
1 | p < 1 / 500 = 0.002
```

这与论文真实数据分析部分的结论一致：LGG 与 GBM 的甲基化水平存在显著分布差异。

3. 单基因边际分布差异

单基因边际检验结果保存在：

```
1 | GBM/GBM_grade_marginal_summary.txt
2 | GBM/GBM_grade_marginal_pvals.txt
3 | GBM/GBM_grade_marginal_statistics.txt
4 | GBM/GBM_grade_marginal_is_significant.txt
```

本次运行中，207 个基因里有：

```
1 | 138 / 207 个基因的边际甲基化分布显著不同
```

解释如下：

- 对每一个基因，分别计算 LGG 与 GBM 在该基因上的一维 Wasserstein 距离统计量。
- 使用全局 MSWD bootstrap 样本构造 simultaneous confidence interval / simultaneous threshold。
- 如果某个基因的边际统计量超过这个 simultaneous threshold，则认为该基因在两组之间存在显著边际分布差异。

因此，结果说明不仅整体甲基化分布不同，而且相当多的单个预后基因也表现出显著的边际差异。

说明：论文正文报告显著边际基因为 139 个；本次复现实验得到 138 个。该差异可能来自随机初始化、bootstrap 随机性、稀疏方向优化的非凸性，以及代码运行环境差异。整体结论不受影响。

4. GO term 基因集合分析

GO term 子集分析结果保存在：

```
1 | GBM/GBM_gene_set_summary.txt
```

本次运行的结果如下：

GO term	基因数	统计量	p-value	是否显著
mitotic_cell_cycle	5	9.466548	0.0	是
mitotic_cell_cycle_process	4	9.464856	0.0	是
cell_cycle_process	7	10.196108	0.0	是
cell_cycle	11	15.454372	0.0	是
DNA_metabolic_process	6	8.729650	0.0	是
cell_division	5	11.125883	0.0	是
mitotic_nuclear_division	3	4.131380	0.0	是

这 7 个 GO biological process 相关基因集合全部显著，说明 LGG 与 GBM 在这些生物过程相关基因的联合甲基化分布上均存在显著差异。

从生物学角度看，这些 GO term 多与细胞周期、细胞分裂、DNA 代谢和有丝分裂有关。论文中也指出，这与已有研究中关于 glioma 向 GBM 进展过程中细胞周期相关基因甲基化变化的发现相一致。

5. QQ 图结果

绘图脚本为：

```
1 GBM-plot/plot_fig2_qq.py
```

生成的图像文件为：

```
1 GBM-plot/Figure2_QQ_GBM.png
2 GBM-plot/Figure2_QQ_GBM.pdf
```

该图复现论文 Fig. 2 的思路：对每个 GO term 基因集合，使用真实数据分析得到的最优投影方向 `direction_*.txt`，将 LGG 和 GBM 的多维甲基化数据分别投影成一维分布，然后绘制两组投影分布的 QQ plot。

图中：

- 横轴为 LGG 组投影后一维分布的分位数。
- 纵轴为 GBM 组投影后一维分布的分位数。
- 虚线为 identity line $y = x$ 。
- 如果曲线明显偏离虚线，说明两组在该投影方向上的分布存在差异。

本次生成的 6 个面板包括：

```
1 Mitotic cell cycle
2 Cell cycle process
3 Cell cycle
4 DNA metabolic process
5 Cell division
6 Mitotic nuclear division
```

这些 QQ 曲线均明显偏离 $y = x$ ，与 GO term 显著性结果一致，说明这些基因集合在 LGG 与 GBM 之间具有显著的投影分布差异。

6. 总结

本次真实数据分析得到三个层面的结论：

1. 全局层面：LGG 与 GBM 的 207 维 DNA 甲基化分布显著不同。
2. 单基因层面：207 个预后基因中有 138 个基因的边际分布显著不同。
3. 基因集合层面：7 个与细胞周期、细胞分裂、DNA 代谢、有丝分裂相关的 GO term 基因集合全部显著。

因此，复现实验支持论文结论：max-sliced Wasserstein distance 与 bootstrap 方法不仅能够检验高维两样本分布差异，还能进一步定位具有显著差异的边际基因和基因集合。