

Experiments

高维两样本 MSWD 检验复现实验报告

MSWD Bootstrapping Reproduction

2026 年 6 月 15 日

摘要

本文基于 Hu 与 Lin 在 *Biometrika* 发表的论文 *Two-sample distribution tests in high dimensions via max-sliced Wasserstein distance and bootstrapping*, 整理当前项目已经完成的三个主要实验。第一个实验复现论文 Figure 1 中 Model A 的方法对比, 但本报告只采用每个信号强度下前 50 次完整 Monte Carlo 运行; 第二个实验单独展示 MSWD 统计量与 bootstrap 零分布的关系; 第三个实验复现论文第 5 节的 LGG/GBM DNA 甲基化真实数据分析。总体结果表明, 稀疏 max-sliced Wasserstein distance 检验在高维稀疏均值差异场景下具有明显功效优势, 并且在真实 GBM 数据中能同时给出全局分布差异、单基因边际差异和 GO term 基因集合差异的定位结果。

1 论文方法与复现实验主线

论文研究高维两样本分布检验问题:

$$H_0 : P = Q, \quad H_1 : P \neq Q,$$

其中 P, Q 是 $\mathbb{R}^p$ 上的两个分布, 维度 p 可以与样本量同阶甚至更大。传统 Wasserstein 距离在高维下受维数灾难影响, 经验距离收敛很慢。论文的核心思想是先把高维样本投影到一维, 再在所有投影方向中寻找 Wasserstein 距离最大的方向。

对于投影方向 v , 一维 Wasserstein 距离记为 $W_1(v^\top X, v^\top Y)$ 。论文定义 max-sliced Wasserstein distance:

$$D(X, Y) = \sup_{\|v\|_2=1} W_1(v^\top X, v^\top Y).$$

在高维情形下, 论文进一步引入稀疏方向集合

$$V_{0,s} = \{v \in \mathbb{R}^p : \|v\|_2 = 1, \|v\|_0 \leq s\},$$

并用经验稀疏 max-sliced Wasserstein distance

$$D_n = \sup_{v \in V_{0,s}} \sup_{f \in \text{Lip}_1} \left\{ \frac{1}{n_1} \sum_{i=1}^{n_1} f(v^\top X_i) - \frac{1}{n_2} \sum_{j=1}^{n_2} f(v^\top Y_j) \right\}$$

构造统计量:

$$T_n = \left(\frac{n_1 n_2}{n_1 + n_2} \right)^{1/2} D_n.$$

检验规则是: 若观测 T_n 大于 bootstrap 零分布的 $1 - \alpha$ 分位数, 则拒绝 H_0 。

该方法的一个重要优势是可以通过 simultaneous confidence intervals, SCI, 在拒绝全局原假设的同时定位显著投影方向、显著边际变量和显著变量子集。因此, 本文三个实验分别对应三个层面:

- 实验一: Model A 下的经验 size/power 方法对比;
- 实验二: 单组样本下 MSWD 统计量和 bootstrap 零分布的机制展示;
- 实验三: LGG 与 GBM DNA 甲基化真实数据分析, 以及边际基因和 GO term 子集定位。

2 实验一: Model A 的 50 次 Monte Carlo 方法对比

2.1 实验配置

实验一对应论文 Figure 1 中的 Model A, 即高维 Gaussian 均值衰减模型:

$$X \sim N(0_p, \Sigma), \quad Y \sim N(\mu, \Sigma),$$

其中

$$\Sigma_{ij} = 0.5^{|i-j|}, \quad \mu_j = 0.8\beta j^{-3}, \quad j = 1, \dots, p.$$

复现实验采用如下配置:

- 样本量: $n_1 = n_2 = 250$;
- 维度: $p = 500$;
- 显著性水平: $\alpha = 0.05$;
- 信号网格: $\beta = 0, 0.2, 0.4, 0.6, 0.8, 1.0$;
- 每个 β 采用前 50 次完整 Monte Carlo 运行;
- Proposed 方法的 bootstrap 次数: $B = 300$;
- L0 稀疏参数候选集合: $\{1, 5, 10, 20, 50\}$, 通过 2-fold cross-validation 选择;
- 正式优化使用 10 次随机初始化重复, bootstrap 内部每次使用 1 次优化重复;
- 对比方法包括 MMD-G、ED₂、BG 和 PW。日志中无法恢复 MMD-L, 因为原始 `main.py` 没有打印 `lapmmd_decision`。

需要注意的是, 论文原始仿真使用 300 次独立重复; 本报告按当前项目要求只写 50 次实验。因此下面的拒绝率应理解为基于 50 次运行的经验估计, 存在一定 Monte Carlo 波动。

2.2 实验结果

表 1: Model A 下前 50 次完整运行的经验拒绝率

β	Proposed	MMD-G	ED ₂	BG	PW
0.0	0.08	0.02	0.02	0.00	0.04
0.2	0.06	0.02	0.02	0.02	0.06
0.4	0.28	0.18	0.18	0.06	0.08
0.6	0.84	0.08	0.08	0.02	0.08
0.8	0.98	0.26	0.30	0.02	0.14
1.0	1.00	0.58	0.56	0.08	0.24




图 1: Model A 下不同方法的经验拒绝率曲线。图使用每个 β 的前 50 次完整运行。

2.3 结果解读

当 $\beta = 0$ 时, 两组分布相同, 拒绝率反映经验 size。Proposed 方法的拒绝率为 0.08, 略高于 $\alpha = 0.05$, 但在 50 次运行下仍可能由 Monte Carlo 波动造成。MMD-G、ED₂、BG 和 PW 在零假设下也都保持较低拒绝率。

当 $\beta > 0$ 时, 两组之间存在均值差异, 而且该差异沿坐标快速衰减。Proposed 方法的功效随 β 快速上升: $\beta = 0.4$ 时为 0.28, $\beta = 0.6$ 时达到 0.84, $\beta = 0.8$ 和 1.0 时接近或达到 1。相比之下, MMD-G 与 ED₂ 虽然也随信号增强而上升, 但整体功效明显低于 Proposed; BG 和 PW 在该模型下更弱。

这与论文 Figure 1 的主要结论一致: 对于高维稀疏或衰减型均值差异, max-type 的稀疏

MSWD 方法比平均型或距离平均型方法更容易捕捉到信号。

3 实验二：MSWD 单独 bootstrap 效用实验

3.1 实验配置

实验二只考察 Proposed 方法本身，不运行其他对比方法。它不是 Monte Carlo power 实验，而是对每个 β 生成一组 Model A 数据，再对这组数据做 $B = 500$ 次 bootstrap，用来观察观测统计量和 bootstrap 零分布之间的相对位置。

配置如下：

$$n_1 = n_2 = 250, \quad p = 500, \quad \alpha = 0.05, \quad B = 500,$$

$$\beta = 0, 0.2, 0.4, 0.6, 0.8, 1.0, \quad \text{signal} = 0.8\beta.$$

统计量仍为

$$T_n = \left(\frac{n_1 n_2}{n_1 + n_2} \right)^{1/2} \hat{D}_{0,s},$$

拒绝规则为 T_n 大于 500 次 bootstrap 统计量的 95% 分位数。

3.2 实验结果

本报告采用当前最终汇总文件 `data/mswd_modelA_single_bootstrap_summary.csv`。结果如下：

表 2: 单组样本下 MSWD 与 bootstrap 阈值的比较

β	signal	observed T_n	threshold	p-value	reject
0.0	0.00	3.442	3.885	0.238	否
0.2	0.16	3.372	3.958	0.372	否
0.4	0.32	3.256	3.918	0.484	否
0.6	0.48	10.557	10.920	0.106	否
0.8	0.64	7.319	4.025	0.000	是
1.0	0.80	9.479	3.921	0.000	是




图 2: 每个 β 下的观测统计量、bootstrap 统计量和 95% 阈值。

3.3 结果解读

该实验的核心作用是解释 MSWD bootstrap 检验的判别机制, 而不是估计 power。对于 $\beta = 0, 0.2, 0.4$, 观测 T_n 均低于 bootstrap 阈值, 因此不拒绝。对于 $\beta = 0.6$, 观测统计量已经很大, 但仍略低于阈值, 属于一次边界附近的未拒绝结果。对于 $\beta = 0.8$ 和 $\beta = 1.0$, 观测统计量明显超过 bootstrap 95% 阈值, 经验 p-value 为 0; 由于 $B = 500$, 更稳妥的表述是 $p < 0.002$ 。

这个实验和实验一并不矛盾。实验一汇总 50 次独立运行, 显示 $\beta = 0.6$ 下 Proposed 的经验功效为 0.84; 实验二只看单组样本, 因此某一个 $\beta = 0.6$ 数据集未拒绝是合理的。

4 实验三：LGG/GBM DNA 甲基化真实数据分析

4.1 实验配置

实验三对应论文第 5 节真实数据分析。数据来自 TCGA lower-grade glioma 与 glioblastoma multiforme 研究，并聚焦 Human Pathology Atlas 中与 glioma prognosis 相关的候选基因。预处理后：

$$n_1 = 511 \quad (\text{LGG}), \quad n_2 = 150 \quad (\text{GBM}), \quad p = 207.$$

检验目标是：

H_0 : LGG 与 GBM 的 207 维甲基化分布相同,

H_1 : 两组甲基化分布不同.

程序设置为 $\alpha = 0.05$, bootstrap 次数 $B = 500$ 。L0 稀疏参数由交叉验证选择，当前运行选择的 λ_0 约为 50。

4.2 全局检验结果

表 3: GBM/LGG 全局两样本检验结果

指标	数值
LGG 样本量	511
GBM 样本量	150
基因维度	207
bootstrap 次数	500
选择的 L0 稀疏参数	50.0000
MSWD 距离	3.9860
检验统计量	42.9236
bootstrap 临界值	1.8479
经验 p-value	0.0, 即 $p < 0.002$
是否拒绝原假设	是

由于观测统计量远大于 bootstrap 阈值，LGG 与 GBM 的 DNA 甲基化分布存在显著差异。这一结论与论文报告的 $p < 10^{-3}$ 一致。

4.3 边际基因和 GO term 子集结果

利用 SCI 机制，本实验进一步识别单基因边际分布差异。当前复现结果显示：

138/207

个预后基因的边际甲基化分布显著不同。论文正文报告为 139 个；当前复现得到 138 个，差异可能来自 bootstrap 随机性、非凸优化初始化和运行环境差异，但整体结论不变。

GO term 基因集合结果如下:

表 4: GO biological process 基因集合分析

GO term	基因数	统计量	是否显著
mitotic_cell_cycle	5	9.467	是
mitotic_cell_cycle_process	4	9.465	是
cell_cycle_process	7	10.196	是
cell_cycle	11	15.454	是
DNA_metabolic_process	6	8.730	是
cell_division	5	11.126	是
mitotic_nuclear_division	3	4.131	是

7 个 GO biological process 子集全部显著, 说明 LGG 与 GBM 的差异集中体现在细胞周期、DNA 代谢、细胞分裂和有丝分裂相关过程上。




图 3: GBM/LGG 在不同 GO term 最优投影方向上的 QQ 图。曲线偏离 $y = x$ 表示投影分布不同。

QQ 图把每个 GO term 的多维甲基化数据沿对应最优方向投影成一维分布, 然后比较 LGG 与 GBM 的分位数。各面板曲线均明显偏离 $y = x$, 与表中显著性结论一致。需要注意, 最优方向 v 与 $-v$ 在 Wasserstein 距离上等价, 因此复现图和论文图在局部面板上可能出现镜像或坐标符号差异, 但不影响统计结论。

5 三个实验的整体理解

三个实验构成了一个完整证据链。实验一回答“方法在论文核心仿真场景中是否有功效优势”: 在高维、稀疏、均值衰减的 Model A 下, Proposed 方法比 MMD-G、ED₂、BG 和 PW 更快获得

高 power。实验二回答“Proposed 方法具体怎样做拒绝判定”：通过 bootstrap 构造零分布阈值，并比较观测 T_n 与 95% 分位数。实验三回答“方法在真实生物数据中能否给出可解释发现”：它不仅拒绝 LGG 与 GBM 甲基化分布相同的全局原假设，还定位了大量显著边缘基因和与肿瘤进展相关的 GO term 基因集合。

从统计角度看，MSWD 方法的优势来自两个方面：第一，max-sliced 结构选择最能区分两组样本的投影方向，减少高维平均效应对稀疏信号的稀释；第二，bootstrap 提供了可操作的高维零分布近似和 SCI 机制，使全局检验与变量/子集定位处于同一套 inferential framework 中。

6 复现文件说明

本报告使用的图片和数据已复制到当前报告目录：

- 实验一：data/modelA_first50_summary.csv, assets/fig1.png;
- 实验二：data/mswd_modelA_single_bootstrap_summary.csv, assets/fig2.png;
- 实验三：data/GBM_global_test_summary.txt, data/GBM_gene_set_summary.txt, data/GBM_grade_marginal_summary.txt, assets/fig3.png;
- 论文来源：data/source_paper.pdf。

参考文献

- [1] Hu, X. and Lin, Z. (2025). *Two-sample distribution tests in high dimensions via max-sliced Wasserstein distance and bootstrapping*. Biometrika, 112(2), asaf001.