

Experiments

高维两样本 MSWD 检验复现实验

MSWD Bootstrapping Reproduction

2026 年 6 月 15 日

论文方法如何连接三个实验

- 目标：检验 $H_0 : P = Q$ 对 $H_1 : P \neq Q$, 允许 p 很大。
- 核心统计量：在稀疏方向上最大化一维 Wasserstein 距离。

$$T_n = \left(\frac{n_1 n_2}{n_1 + n_2} \right)^{1/2} \sup_{v \in V_{0,s}} W_1(v^\top X, v^\top Y).$$

- 判定：观测 T_n 超过 bootstrap 零分布的 $1 - \alpha$ 分位数则拒绝。
- SCI：同一套 bootstrap 机制还能定位显著边际变量和 GO term 子集。


三个实验的角色

实验	问题	输出
Model A 方法对比	MSWD 在论文核心仿真场景下是否有 power 优势	50 次运行的经验拒绝率曲线
MSWD 单独 bootstrap	一次样本下统计量如何与零分布比较	观测 T_n 、bootstrap 阈值、p-value
GBM 真实数据	LGG 与 GBM 甲基化分布是否不同，差异在哪里	全局检验、138 个边际基因、7 个 GO term

实验一配置: Model A 前 50 次 Monte Carlo

- 模型: $X \sim N(0_p, \Sigma)$, $Y \sim N(\mu, \Sigma)$ 。
- 协方差: $\Sigma_{ij} = 0.5^{|i-j|}$ 。
- 均值衰减: $\mu_j = 0.8\beta j^{-3}$ 。
- 参数: $n_1 = n_2 = 250$, $p = 500$, $\alpha = 0.05$ 。
- 信号: $\beta = 0, 0.2, 0.4, 0.6, 0.8, 1.0$ 。
- 每个 β 写作 50 次完整实验; Proposed 方法 bootstrap $B = 300$ 。
- 对比: MMD-G、ED₂、BG、PW; MMD-L 不能从日志恢复。

实验一结果：Proposed power 上升最快




β	Proposed	MMD-G	ED ₂	BG	PW
0.0	0.08	0.02	0.02	0.00	0.04
0.4	0.28	0.18	0.18	0.06	0.08
0.6	0.84	0.08	0.08	0.02	0.08
0.8	0.98	0.26	0.30	0.02	0.14
1.0	1.00	0.58	0.56	0.08	0.24

- $\beta = 0$ 下 size 约 0.08, 50 次实验下可视为 Monte Carlo 波动。
- $\beta = 0.6$ 后 Proposed 明显拉开差距, 符合论文对稀疏衰减信号的判断。

实验二配置：单样本 MSWD bootstrap

- 每个 β 只生成一组 Model A 数据。
- 对这一组数据做 $B = 500$ 次 bootstrap。
- 目的不是估计 power, 而是展示拒绝机制。
- 拒绝规则: observed T_n 大于 bootstrap 95% 阈值。
- 参数: $n_1 = n_2 = 250$, $p = 500$, $\alpha = 0.05$ 。

实验二结果：强信号下观测统计量超过阈值



β	observed T_n	threshold	p-value	reject
0.0	3.442	3.885	0.238	否
0.2	3.372	3.958	0.372	否
0.4	3.256	3.918	0.484	否
0.6	10.557	10.920	0.106	否
0.8	7.319	4.025	0.000	是
1.0	9.479	3.921	0.000	是

- $\beta = 0.6$ 是边界附近未拒绝；这不等同于 power 低。
- 500 次 bootstrap 下 p-value 为 0，应写作 $p < 0.002$ 。

实验三配置：LGG/GBM DNA 甲基化

- 数据：TCGA LGG 与 GBM DNA methylation。
- 样本： $n_1 = 511$ 个 LGG, $n_2 = 150$ 个 GBM。
- 变量： $p = 207$ 个 glioma prognosis 相关基因。
- 方法：L0 sparse MSWD + bootstrap, $B = 500$, $\alpha = 0.05$ 。
- 目标：检验两组 207 维甲基化分布是否相同，并定位差异。

实验三全局结果：LGG 与 GBM 显著不同

指标	数值
检验统计量	42.9236
bootstrap 临界值	1.8479
经验 p-value	$p < 0.002$
显著边际基因	138 / 207
显著 GO term	7 / 7

- 全局统计量远高于阈值，拒绝甲基化分布相同的原假设。
- 论文报告 139 个显著边际基因；当前复现为 138 个，整体结论一致。


实验三 GO term 结果

GO term	基因数	统计量
mitotic cell cycle	5	9.467
mitotic cell cycle process	4	9.465
cell cycle process	7	10.196
cell cycle	11	15.454
DNA metabolic process	6	8.730
cell division	5	11.126
mitotic nuclear division	3	4.131

七个集合全部显著，差异集中在细胞周期、DNA 代谢、细胞分裂和有丝分裂相关过程。

实验三 QQ 图：投影分布明显偏离

QQ plots of projected methylation distributions



- 实验一：MSWD 在 Model A 稀疏衰减均值差异下具备最强 power。
- 实验二：bootstrap 阈值解释了 Proposed 方法如何做拒绝判定。
- 实验三：真实 GBM 数据中，全局分布、边际基因和 GO term 层面都显著。
- 方法优势：max-sliced 方向搜索减少信号稀释；SCI 机制把检验和定位统一起来。